Детекция дефектов речи с помощью скороговорок

Кузьмин Дмитрий Андреевич

Факультет компьютерных наук НИУ ВШЭ
Программа «Искусственный интеллект»

Научный руководитель: Кантонистова Елена Олеговна
Соруководитель: Ковалева Александра Ивановна

Москва, 2026

Мотивация

Проблема

- Нарушения речи у детей влияют на обучение и социальную адаптацию
- Диагностика требует оценки логопеда
- Регулярный мониторинг динамики

Типы причин дефектов речи

- недоразвитость речевого аппарата;
- поражение нервной системы (дизартрия, афазия и др.);
- дефекты речевого аппарата (ринолалия и др.).

Решение

- Автоматическая система с возможностью контроля динамики
- Скороговорки - лучший способ выявления

Постановка задачи

- **Тип задачи:** бинарная классификация аудиозаписей детской речи
- **Вход:** аудиофайл чтения скороговорки x_i; **выход:** $y_i \in \{0, 1\}$
- **Классы:** **good** (нормальное произношение), **bad** (наличие речевого дефекта)
- **Прикладная цель:** Telegram-бот для мониторинга динамики

Описание датасета

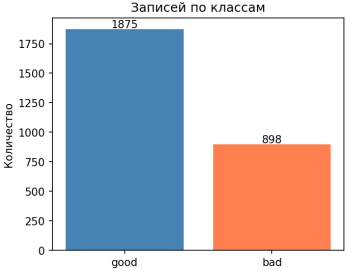

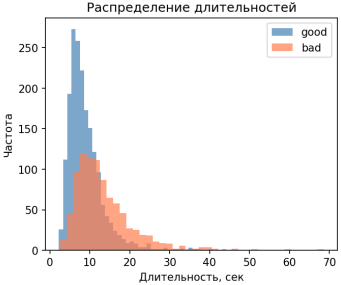

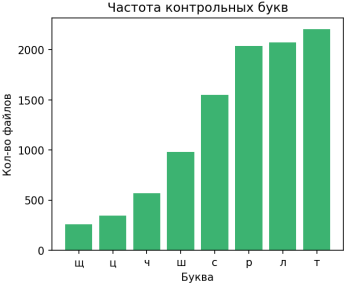

Ключевые особенности:

- Малый объём (2773 записи)
- Дисбаланс классов (2/3 — good)
- Каждая запись помечена $\geq$1 контрольной буквой (т, л, р, с, ш, ч, ц, щ)

Длительность аудио (сек.)

	min	max	mean	median
good	2.28	44.10	8.89	7.86
bad	2.62	68.66	13.47	11.84
all	2.28	68.66	10.37	8.86

Метрики оценки качества

Иерархия важности метрик:

1. $\mathrm{F1}_{\mathrm{bad}}$ — ключевая (не пропустить дефект)
2. $F1_{\mathrm{macro}}$ — баланс по классам
3. Accuracy — общий индикатор

Группа 1: Классические ML-модели

Результаты:

Модель	**F1-bad**	**F1-macro**	**Acc**
MFCC + RF	0.540	0.679	0.739
VGGish + SVM	**0.597**	**0.692**	**0.722**

Группа 2: Нейронные сети на спектрограммах

Результаты:

Модель	F1-bad	F1-macro	Acc
1D CNN (waveform)	0.561	0.689	0.741
2D CNN (log-mel)	0.567	0.673	0.707
BiLSTM (MFCC)	0.530	0.656	0.703
Swin Tiny (mel)	0.597	0.718	0.770
DSSCNet	**0.624**	**0.716**	**0.746**
FluentNet	0.610	0.686	0.705

Группа 3: Предобученные речевые эмбеддинги

Результаты:

Модель	F1-bad	F1-macro	Acc
Wav2Vec2 + SVM	0.617	0.717	0.753
HuBERT + SVM	0.628	0.745	0.799
OpenL3 + SVM	0.664	0.750	0.779
XLS-R + SVM	0.642	0.747	0.791
Whisper-small + SVM	0.722	0.799	0.830
Whisper-med + SVM	**0.747**	**0.815**	**0.839**
Whisper-large + SVM	0.724	0.802	0.832
Whisper-special + SVM	0.644	0.751	0.796

Улучшения пайплайна

Аспект	**Текущий пайплайн**	**Улучшения**
CV	Один сплит	5-fold Stratified CV на train+val
Порог	0.5 фиксированный	Оптимальный для максимума F1-bad на val
Аугментация	Нет	Планируется

Заключение

Ключевой вывод:
Предобученные речевые модели (Whisper, HuBERT) обеспечивают наилучшую детекцию дефектов речи при малом объёме данных

Дальнейшие шаги:

- Fine-tuning предобученных моделей
- Аугментация для DL моделей
- Мультиклассовая постановка (по типу дефекта)
- Объяснимость: визуализация активаций
- Написание сервиса (Telegram-бота) для мониторинга динамики

Спасибо за внимание