# Детекция дефектов речи с помощью скороговорок

Кузьмин Дмитрий Андреевич

Факультет компьютерных наук НИУ ВШЭ
Программа «Искусственный интеллект»

Научный руководитель: Кантонистова Елена Олеговна
Соруководитель: Ковалева Александра Ивановна

Москва, 2026

# Мотивация

**Проблема**

- Нарушения речи у детей влияют на обучение и социальную адаптацию
- Диагностика требует оценки логопеда
- Регулярный мониторинг динамики

**Типы причин дефектов речи**

- недоразвитость речевого аппарата;
- поражение нервной системы (дизартрия, афазия и др.);
- дефекты речевого аппарата (ринолалия и др.).

**Решение**

- Автоматическая система с возможностью контроля динамики
- Скороговорки - лучший способ выявления

# Постановка задачи

- **Тип задачи:** бинарная классификация аудиозаписей детской речи
- **Вход:** аудиофайл чтения скороговорки $x_i$; **выход:** $y_i \in \{0, 1\}$
- **Классы:** **good** (нормальное произношение), **bad** (наличие речевого дефекта)
- **Прикладная цель:** Telegram-бот для мониторинга динамики

# Описание датасета

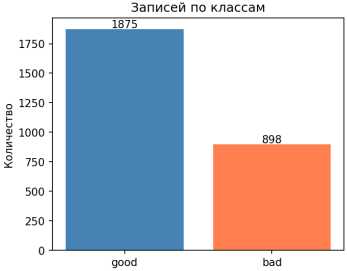


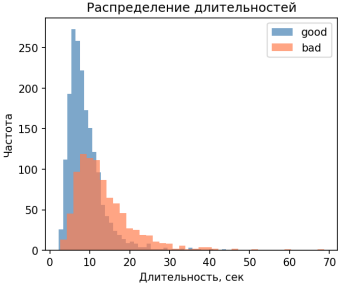


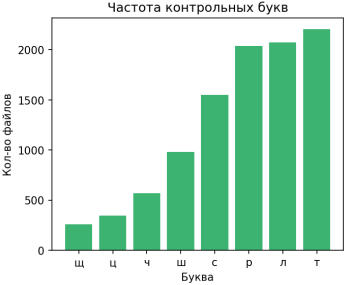


**Ключевые особенности:**

- Малый объём (2773 записи)
- Дисбаланс классов (2/3 — good)
- Каждая запись помечена $\geq$1 контрольной буквой (т, л, р, с, ш, ч, ц, щ)

**Длительность аудио (сек.)**

| | min | max | mean | median |
|---|---|---|---|---|
| good | 2.28 | 44.10 | 8.89 | 7.86 |
| bad | 2.62 | 68.66 | 13.47 | 11.84 |
| all | 2.28 | 68.66 | 10.37 | 8.86 |

# Метрики оценки качества

**Иерархия важности метрик:**

1. $\mathrm{F1}_{\mathrm{bad}}$ — ключевая (не пропустить дефект)
2. $F1_{\mathrm{macro}}$ — баланс по классам
3. Accuracy — общий индикатор

# Группа 1: Классические ML-модели

**Результаты:**

| **Модель** | **F1-bad** | **F1-macro** | **Acc** |
|---|---|---|---|
| MFCC + RF | 0.540 | 0.679 | 0.739 |
| **VGGish + SVM** | **0.597** | **0.692** | **0.722** |

# Группа 2: Нейронные сети на спектрограммах

**Результаты:**

| Модель | F1-bad | F1-macro | Acc |
|---|---|---|---|
| 1D CNN (waveform) | 0.561 | 0.689 | 0.741 |
| 2D CNN (log-mel) | 0.567 | 0.673 | 0.707 |
| BiLSTM (MFCC) | 0.530 | 0.656 | 0.703 |
| Swin Tiny (mel) | 0.597 | 0.718 | 0.770 |
| **DSSCNet** | **0.624** | **0.716** | **0.746** |
| FluentNet | 0.610 | 0.686 | 0.705 |

# Группа 3: Предобученные речевые эмбеддинги

**Результаты:**

| Модель | F1-bad | F1-macro | Acc |
|---|---|---|---|
| Wav2Vec2 + SVM | 0.617 | 0.717 | 0.753 |
| HuBERT + SVM | 0.628 | 0.745 | 0.799 |
| OpenL3 + SVM | 0.664 | 0.750 | 0.779 |
| XLS-R + SVM | 0.642 | 0.747 | 0.791 |
| Whisper-small + SVM | 0.722 | 0.799 | 0.830 |
| **Whisper-med + SVM** | **0.747** | **0.815** | **0.839** |
| Whisper-large + SVM | 0.724 | 0.802 | 0.832 |
| Whisper-special + SVM | 0.644 | 0.751 | 0.796 |

# Улучшения пайплайна

| **Аспект** | **Текущий пайплайн** | **Улучшения** |
|---|---|---|
| CV | Один сплит | 5-fold Stratified CV на train+val |
| Порог | 0.5 фиксированный | Оптимальный для максимума F1-bad на val |
| Аугментация | Нет | Планируется |

# Заключение

**Ключевой вывод:**
Предобученные речевые модели (Whisper, HuBERT) обеспечивают наилучшую детекцию дефектов речи при малом объёме данных

**Дальнейшие шаги:**

- Fine-tuning предобученных моделей
- Аугментация для DL моделей
- Мультиклассовая постановка (по типу дефекта)
- Написание сервиса (Telegram-бота) для мониторинга динамики

Спасибо за внимание